Final project: 48-hour electricity generation forecast

MATH840 Time Series

Tetiana Mazko

5 November 2026

Анотація

Ми прогнозуємо погодинну генерацію електроенергії на наступні 48 годин із 95% prediction interval. Фінальна модель — це комбінація моделі LightGBM (30%) та Chronos-2 із погодними коваріатами (70%). На відкладених даних ця комбінація має RMSE приблизно на 30% нижчий, ніж сезонний наївний benchmark (skill ≈ 0.70), а також значно нижчий Winkler score.

1. What is in the series?

Data. `train.csv` містить 33 480 погодинних значень із 2023-01-01 до 2026-10-27 00:00 (приблизно 199 тижнів), а також фактичні погодні дані (хмарність, температура, вітер, тиск, вологість, прапорець світлового дня, щільність повітря). Пропусків, дублікатів, від'ємних значень або відсутніх даних немає. Послідовності з трьох або більше однакових значень трапляються рідко (67 послідовностей, 299 годин, 0.9%), тому ми не стали їх окремо обробляти. `weather_forecast.csv` містить прогноз погоди на 48 годин, які потрібно спрогнозувати.

Patterns.

- **Daily cycle.** Генерація досягає піку приблизно о 12–14 годині та має вигляд, характерний для сонячної генерації. Нічні значення не дорівнюють нулю: середній місячний нічний рівень становить приблизно 100–200, а за останній тиждень — 30–170. Ефекту дня тижня немає.
- **Level shift.** Середні добові значення становили приблизно 100–400 у 2023–2025 роках і близько 600–1400 у 2026 році (імовірно, було додано потужності). Через це кореляції з погодою на всьому часовому ряді слабкі (0.16–0.39), а моделі, навчені на початковому рівні ряду, дають оманливі результати.
- **Falling level now.** Добові піки знизилися приблизно з 2700 (17 жовтня) до 800–1150 (23–26 жовтня). Це падіння не пояснюється лише хмарністю: 23 та 25 жовтня хмарність удень дорівнювала 0, але піки все одно становили лише 1033 та 793. Проте точна причина(сезонність, обмеження генерації, потужності) невідома.
- **Weather.** Нічна генерація залежить від вітру (Spearman 0.63 за березень–жовтень 2026 року), тому можна припустити, що частина електроенергії виробляється вітровими електростанціями. Денний пік відносно трьох попередніх піків також пов'язаний із вітром (0.46), а з хмарністю лише трохи (0.11).

- **Clock change.** Вікно світлового дня зміщується на одну годину в перший день горизонту (раніше 8–16, у прогнозі 7–15). Те саме відбувалося в попередні роки. Форма y відповідала прапорцю у 4 із 7 випадків переходу часу

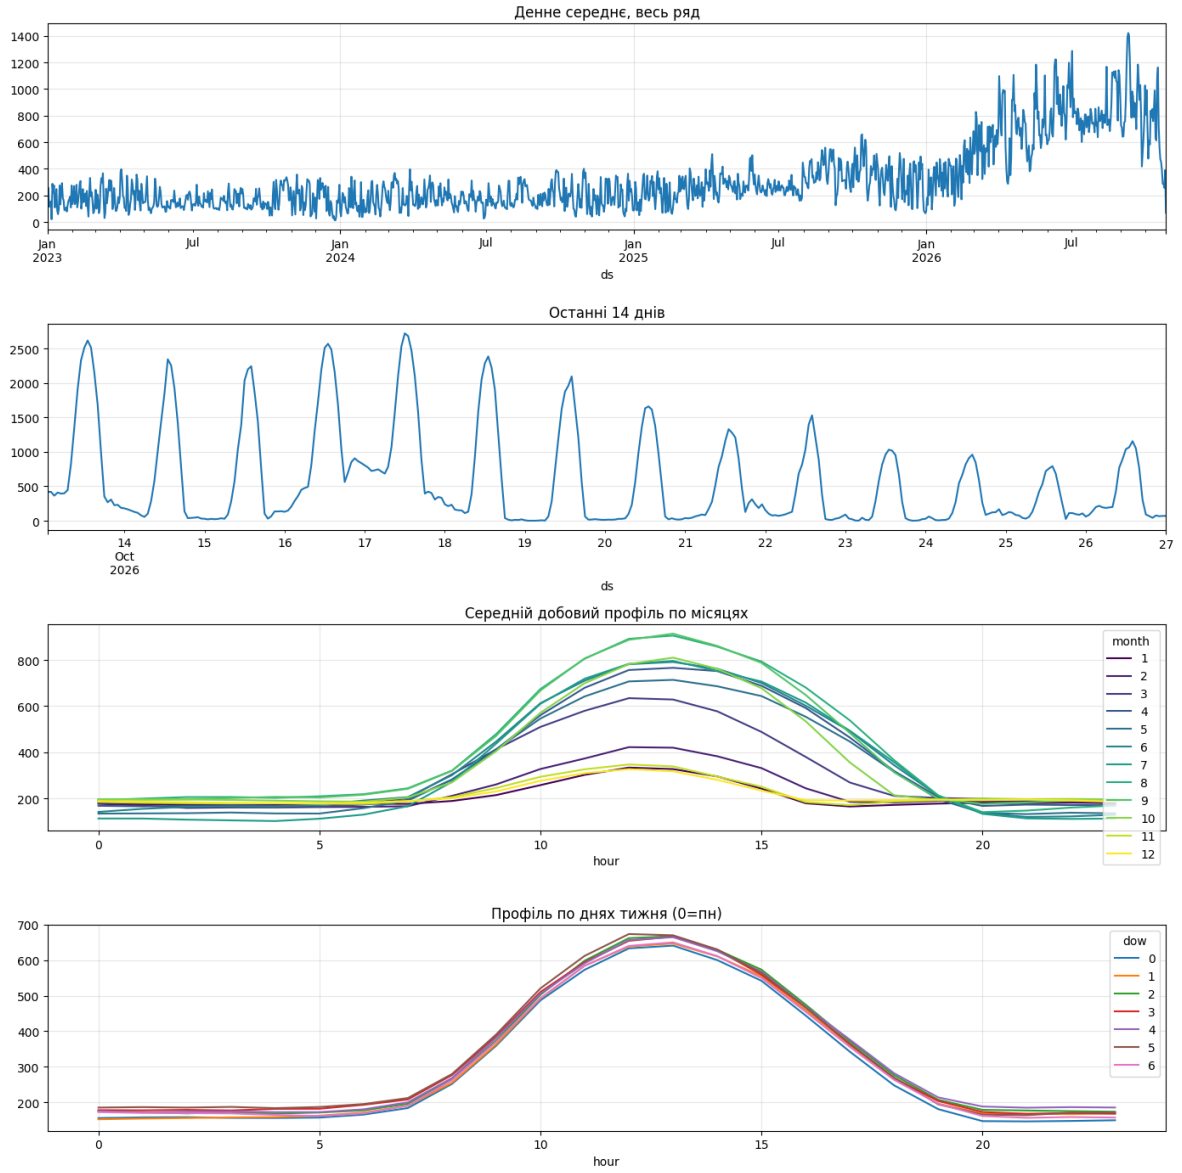


Рис. 1: Середнє добове значення всього часового ряду, останні 14 днів і добовий профіль за місяцями.

How this shaped the model.

- Кожна цільова змінна ділиться на середнє значення за останні 7 днів, lv7, щоб рівні можна було порівнювати.
- Нещодавні дні (лаги, мінімум і максимум останнього дня, рівні за 1/3/14 днів) є важливими ознаками. У фінальній LightGBM три лагові ознаки забезпечують близько 80% gain.
- Нічний результат нижчий, ніж модель спочатку прогнозувала, тому було додано нічний множник (Section 3).

- Прогноз погоди *використовується*, оскільки без погоди моделі були помітно гіршими (Section 3). Прогноз для піку другого дня дуже чутливий до хмарності: зміна прогнозу хмарності на ± 0.25 змінює пік другого дня приблизно з 970 до 1190.

2. How did we check the forecast?

Setup. Кожна опівніч у даних — точка відліку для прогнозу на 48 годин. Для валідації я використовую останні **240 точок** (8 блоків по 30), навчаючи модель без витоку даних: трейн завжди закінчується щонайменше за 48 годин до початку тестового блоку. Метрики обчислюю виключно для **day 2** (години 25–48), який визначає фінальний рейтинг. Результати наводжу для двох вибірок: **all** (усі 240 точок) та **low** (84 точки із 7-денним рівнем $< 2 \times 363$, що максимально наближено до поточних умов горизонту).

Weather in validation. Під час навчання я використовую фактичну погоду, а на горизонті — лише метеопрогноз. Щоб наблизити валідацію до реальності, я додавала до тестової погоди випадковий шум (з більшою похибкою для другого дня). Оскільки історії реальних метеопомилок немає, розмір шуму був орієнтовним припущенням. Проте він погіршив метрики LightGBM лише на 3–4

Comparing models. Усі моделі порівнювалися на тих самих моментах прогнозування за допомогою paired block bootstrap (блоки по 7 моментів прогнозування, 2000 повторних вибірок), із зазначенням 95% інтервалу різниці в RMSE, MAPE та Winkler. Різниця вважається реальною лише тоді, коли інтервал не містить 0. Варто зазначити що на тих самих 240 моментах прогнозування було випробувано багато варіантів, тому найкращі результати дещо оптимістичні.

Benchmark — сезонний наївний прогноз на тих самих моментах прогнозування.

3. Models and results

LightGBM. Модель прогнозує 48 годин на основі 23 ознак: година, день року, індекс дня та крок прогнозного горизонту, погода для цільової години, три лаги (та сама година 1, 2, 3 дні тому), рівні за 1/3/14 днів, максимум і мінімум останнього дня, максимум за 3 дні, останнє відоме значення, а також середня хмарність і вітер у світлу пору цільового дня (усі значення поділені на lv7).

Налаштування: 400 дерев, learning rate 0.03, 15 leaves, 3 seeds, ваги вибірок дорівнюють lv7, помноженому на експоненційне згасання з half-life 180 днів. Прогнози множаться на lv7 та на 0.8 у нічний час.

Feature ablation (90 моментів прогнозування, фактична погода, day 2). Агреговані добові погодні ознаки переважно покращили MAPE, а лагові та нічні ознаки переважно покращили RMSE. Найкращий результат дала їх комбінація.

Variant	RMSE	MAPE
Seasonal naive	328.0	320.5
First feature set (A)	290.4	277.4
A + daily weather aggregates	284.2	176.5
A + extra lags and levels	270.9	246.3
All features, no decay	268.0	158.6
All features + decay (G)	259.3	140.8

Табл. 1: Ablation. Шум від seed становить приблизно ± 1.5 RMSE та ± 7 MAPE.

Night multiplier. Модель завищувала нічні значення (MAPE є великим для малих значень y). Множник 0.8 для нічних годин знизив MAPE на 16 пунктів (paired 95% interval $[-26, -8]$ порівняно з варіантом без множника), а також трохи знизив RMSE. Множник 0.65 давав нижчий MAPE, але вищий RMSE (+3.5), тому ми залишили 0.8.

Training window. Навчання лише на останніх 365 днях дало кращий результат, ніж навчання на всій історії (paired різниця RMSE $+7.3$, інтервал $[+0.4, +15.8]$ на *low*). Коротші вікна давали гірші результати.

LightGBM window (subset *low*)	RMSE	MAPE	Winkler
Full history, half-life 180 d	236.3	78.9	1152
Last 365 days (candidate A)	**228.8**	**73.6**	**1086**
Last 180 days	233.1	84.6	1122
Last 120 days	245.2	93.4	1173
Last 90 days	238.5	91.2	1191
Last 60 days	246.2	96.7	1278
Last 45 days	258.1	97.6	1364
Last 30 days	258.0	101.6	1355

Табл. 2: Training window.

Дуже короткі вікна мають замало рядків і втрачають сезонну форму.

Інші зміни не дали покращення, яке виходило б за межі шуму: hyper-parameters (leaves, trees, regularisation), sample weights (lv7, 1, lv7^2), додаткові нічні wind features, а також додавання копій погодних даних із шумом до навчальної вибірки.

Chronos. Chronos-Bolt (без погоди) був слабшим за саму LightGBM, а його комбінація у співвідношенні 70/30 не була статистично значуще кращою. Chronos-2 *із погодою як коваріатами* (минулі та майбутні значення) був значно кращим за Chronos-2 без коваріат, а також кращим за LightGBM. Я запускала його на контексті з останніх C годин, брала медіану та застосовувала той самий нічний множник 0.8.

Model (day 2)	*low* (84)			*all* (240)		
	RMSE	MAPE	Wink.	RMSE	MAPE	Wink.
Seasonal naive	292.5	120.2	1357	302.3	194.1	1543
LightGBM, previous public file	234.3	79.3	1120	235.4	91.2	1263
LightGBM, last 365 d (A)	228.8	73.6	1086	231.4	90.1	1255
Chronos-2, no covariates, C=1008	267.2	105.2	1271	263.2	125.9	1451
Chronos-2 + weather, C=504	215.9	70.7	967	227.1	78.0	1145
Chronos-2 + weather, C=672	214.4	76.9	965	223.8	76.4	1149
Chronos-2 + weather, C=1008	211.1	80.2	963	219.1	77.0	1116
Chronos-2 + weather, C=1440	210.1	73.9	940	211.4	71.3	1087
Chronos-2 + weather, C=1800	211.4	72.2	942	211.4	71.3	1082
Chronos-2 + weather, C=2160	210.9	74.5	961	210.0	72.2	1088
Chronos-2 + weather, C=2400	268.9	95.0	1288	264.3	107.9	1481
0.5 A + 0.5 Chronos-2 (C=1440)	205.9	71.3	947	206.6	78.3	1107
0.3 A + 0.7 Chronos-2 (C=1440)	**204.2**	**71.9**	**931**	**204.8**	**74.8**	**1086**

Табл. 3: Порівняння моделей та впливу довжини контексту Chronos-2 на метрики (day 2, розширення інтервалу 1.2).

Експерименти з довжиною контексту показали, що розширення вікна до 60–90 днів ($C \in [1440, 2160]$) дозволило нейромережі оптимально вловити поточний тренд осіннього спаду. Однак подальше збільшення контексту до 100 днів (C=2400) призвело до різкої деградації моделі, оскільки в поле зору потрапили високі літні піки генерації.

Зважаючи на те, що контекст C=1440 показав найкращі результати на релевантній підвибірці *low*, фінальним вибором стала комбінація 30% LightGBM та 70% Chronos-2 (C=1440). Такий бленд забезпечив мінімальний RMSE, найкращий Winkler score та Skill Score на рівні 0.68, що означає беззаперечну перевагу над наївним прогнозом. Оскільки архітектура моделі не дозволяє прямо виміряти важливість окремих ознак, ми не можемо запевнитися чому саме коваріати на стільки допомагать, проте імовірно Chronos-2 ефективно пов’язує прогноз погоди з вивченою довгою історією.

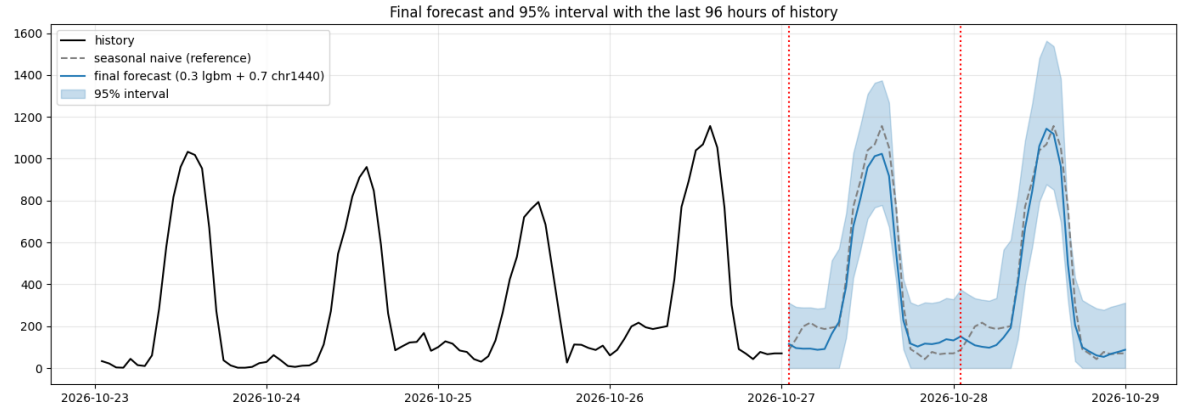


Рис. 2: Останні 96 годин, seasonal naive та фінальний прогноз із 95% інтервалом.

4. How good is the interval?

Construction. Для кожної групи (day 1 / day 2, день / ніч) я розраховую 2.5% та 97.5% квантилі залишків, попередньо поділених на поточний рівень lv7. Далі перевожу їх назад у мегавати, додаю до точкового прогнозу і розширюю в 1.2 раза (найменший множник, що дає coverage ≈ 0.95). Нижня межа обмежується нулем.

Checks. При валідації (leave-one-block-out) фінальний бленд дає coverage 0.943 та Winkler 931 на підвибірці *low* (на *all* — 0.968 та 1086). Якщо калібрувати інтервал виключно на минулих блоках (forward calibration), надійність падає, оскільки масштаб похибки з часом змінюється:

Calibration (*low*, factor 1.2)	Winkler	Coverage
Leave-one-block-out	1086	0.95
Forward (past blocks only)	1283	0.94

Табл. 4: Вплив методу калібрування на надійність інтервалу (розраховано для LightGBM A).

Покриття (coverage) протягом доби нерівномірне: без розширення (множник 1.0) воно падає до 0.8 у години пікового навантаження (11–14), залишаючись надмірним уночі. Специфічні нічні інтервали або мультиплікативні підходи не дали статистично значущого покращення, тому я від них відмовилася.

5. What is left, and what did not work

Residuals of the final model. Аналіз залишків фінальної комбінації (0.3 LightGBM + 0.7 Chronos 1440h) підтверджує відсутність глобального систематичного зміщення:

- **Залишки за годинами доби:** медіани помилок для всіх годин лежать чітко на нульовій лінії. Вдень дисперсія закономірно більша, але системного провалу в конкретні пікові години немає.
- **Фактичні vs прогнозовані значення:** модель чудово відпрацьовує низькі та середні обсяги генерації, хоча злегка згладжує (недооцінює) найвищі екстремальні піки (понад 2000 МВт).
- **Автокореляція (ACF):** залишки не мають значущої автокореляції і виглядають як «білий шум». Бленд успішно витягнув з історичних даних усю корисну інформацію про сезонність та тренд.
- **Bias у періоди падіння рівня:** на відміну від соло-LightGBM, який не встигав за різким осіннім падінням генерації (недооцінював факт), додавання Chronos із довгим контекстом повністю згладило цю проблему.

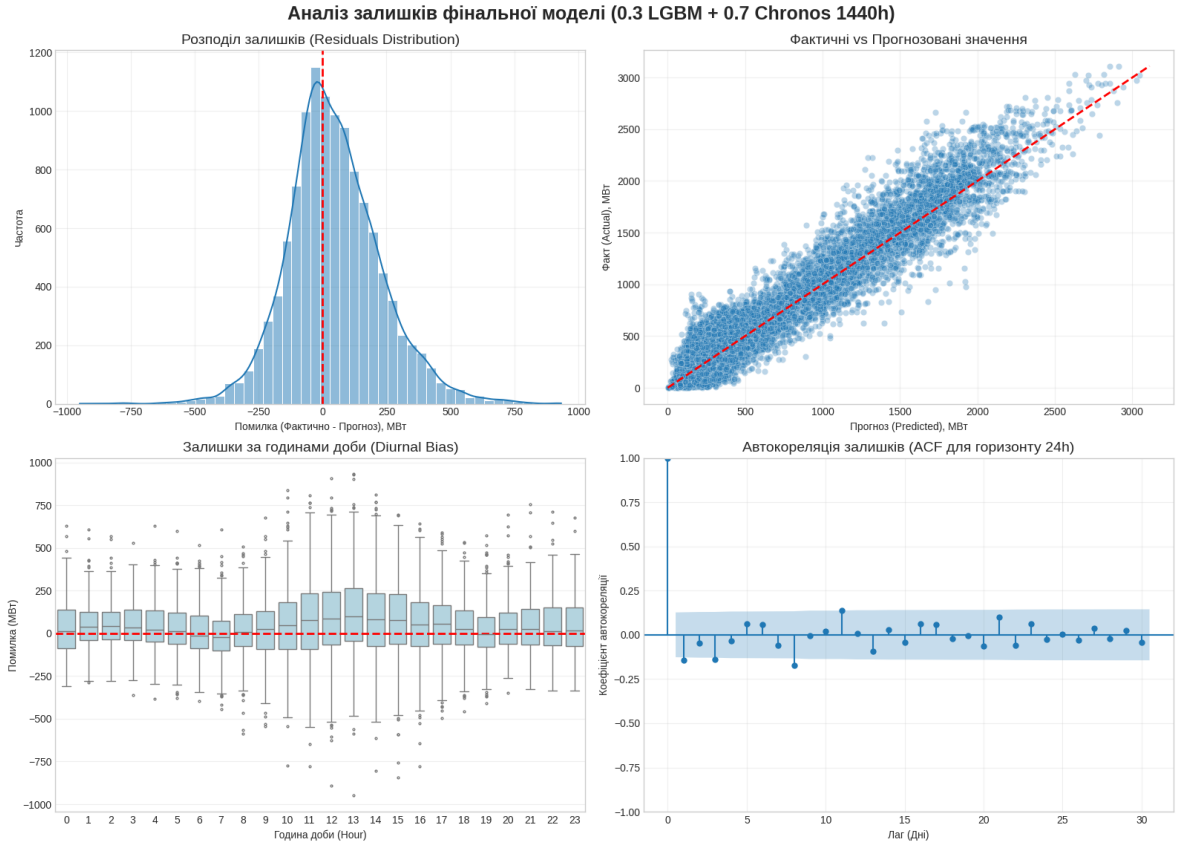


Рис. 3: Аналіз залишків фінальної комбінації: розподіл, фактичні vs прогнозовані значення, похибка за годинами та автокореляція.

Approaches that did not work.

- **ETS and SARIMAX** (log scale, 14–28 днів, погода для SARIMAX): RMSE приблизно вдвічі вищий за benchmark (співвідношення 2.06 та 2.12). Вони погано відстежують зміну рівня піків.
- **Mean of the last 3 days**: результати приблизно на рівні benchmark.
- **LightGBM without weather**: помітно гірша за модель із погодою.
- **Chronos-Bolt and Chronos-2 without covariates**: гірші за соло-LightGBM.
- **Hyper-parameter tuning, sample weights, extra wind features**: відмінності залишилися в межах шуму.
- **Very short training windows (30–120 days)**: значно гірші результати.
- **Quantile regression for the interval** (LightGBM з $\alpha = 0.025, 0.975$): результати в середньому за 3 блоки виглядали кращими (Winkler 1202–1245 проти 1562), але на останньому блоці перевага зникла, а фінальна збірка була неузгодженою з validation (інтервал був надто широким). Я відмовилася від цього підходу.
- **Multiplicative interval** та **night-specific intervals**: не дали підтвердженого покращення.

Public leaderboard. Мій попередній файл LightGBM (повна історія, навчання з зашумленою погодою, широкий інтервал) отримав RMSE 126.9, MAPE 81.0% та Winkler 549 на перших 24 прихованих годинах (порівняно з 115.7, 84.3% та 521 для benchmark). Оскільки це вибірка лише з одного дня, я не вважаю це репрезентативним доказом слабкості моделі. Високий Winkler score зумовлений надто широким інтервалом того сабмішну (coverage 100%).

Main risks.

- У validation використовується зашумлена *фактична* погода, але реальні похибки метеопрогнозів невідомі (і зазвичай зростають на другий день горизонту).
- Довжину контексту, ваги комбінації, нічний множник та множник інтервалу я підбирала на одних і тих самих 240 моментах прогнозування (ризик перенавчання на валідації).
- Chronos-2 — це pretrained model; я не можу дослідити її внутрішню логіку, а її інференс вимагає значних обчислювальних ресурсів.

6. Final submission

Фінальний точковий прогноз: $0.3\times$ LightGBM (останні 365 днів, 3 seeds, нічний множник 0.8) $+$ $0.7\times$ Chronos-2 (погодні коваріати, context 1440 h, нічний множник 0.8).

Інтервал: квантилі *out-of-fold* залишків самого бленду за днем і світловим часом доби, розширені в 1.2 раза, з нижньою межею 0. Калібрування інтервалу безпосередньо на залишках комбінації дозволило зробити його вужчим і мінімізувати штраф у Winkler score.

На відкладених даних цей підхід приблизно на 30% кращий за сезонний наївний benchmark за RMSE (skill 0.70 на *low*, 0.68 на *all*) та має Winkler score приблизно на 30% нижчий. Код, файли даних та інструкції із запуску розміщені в моєму репозиторії.